

РЕФЕРАТ

Дипломная работа: с., рис., табл., прил., источн. Ключевые слова: GPS-ТРАЕКТОРИИ, ПРОФИЛЬ ПОЛЬЗОВАТЕЛЯ, МАШИННОЕ ОБУЧЕНИЕ, ГЕОДАННЫЕ, ПРОСТРАНСТВЕННО-ВРЕМЕННЫЕ ДАННЫЕ, АНАЛИЗ ТРАЕКТОРИЙ, ПОВЕДЕНИЕ ПОЛЬЗОВАТЕЛЯ.

Объект исследования – GPS-траектории пользователей.

Цель работы – разработка и исследование подходов к построению профиля пользователя на основе GPS-траекторий с использованием методов машинного обучения.

В работе рассмотрены существующие подходы к анализу GPS-траекторий и построению профиля пользователя по данным о его местоположении. Исследованы особенности пространственно-временных данных и методы их обработки.

Разработано программное средство для анализа траекторий пользователей и построения пользовательского профиля. Проведено экспериментальное исследование на реальных данных, позволившее оценить эффективность предложенного подхода.

Полученные результаты могут быть использованы в системах анализа мобильности пользователей, сервисах персонализации и интеллектуальных геоинформационных системах.

РЭФЕРАТ

Дыпломная работа: с., рыс., табл., дадат., крыніц.

Ключавыя словы: GPS-ТРАЕКТОРЫІ, ПРОФІЛЬ КАРЫСТАЛЬНІКА, МАШЫННАЕ НАВУЧАННЕ, ГЕАДАДЗЕННЫЯ, ПРАСТОРАВА-ЧАСАВЫЯ ДАДЗЕННЫЯ, АНАЛІЗ ТРАЕКТОРЫЙ, ПАВОДЗІНЫ КАРЫСТАЛЬНІКА.

Аб’ект даследавання – GPS-траекторыі карыстальнікаў.

Мэта работы – распрацоўка і даследаванне падыходаў да пабудовы профілю карыстальніка на аснове GPS-траекторый з выкарыстаннем метадаў машыннага навучання.

У рабоце разгледжаны існуючыя падыходы да аналізу GPS-траекторый і пабудовы профілю карыстальніка па даных аб яго месцазнаходжанні. Даследаваны асаблівасці прасторава-часавых даных і метады іх апрацоўкі.

Распрацаваны праграмны сродак для аналізу траекторый карыстальнікаў і пабудовы карыстальніцкага профілю. Праведзена эксперыментальнае даследаванне на рэальных даных, якое дазволіла ацаніць эфектыўнасць прапанаванага падыходу.

Атрыманыя вынікі могуць быць выкарыстаны ў сістэмах аналізу мабільнасці карыстальнікаў, сэрвісах персаналізацыі і інтэлектуальных геаінфармацыйных сістэмах.

ABSTRACT

Diploma thesis: pages, figures, tables, appendices, references.

Keywords: GPS TRAJECTORIES, USER PROFILE, MACHINE LEARNING, GEOLOCATION DATA, SPATIO-TEMPORAL DATA, TRAJECTORY ANALYSIS, USER BEHAVIOR.

The object of the research is GPS trajectories of users.

The purpose of the thesis is to develop and investigate approaches to user profile construction based on GPS trajectories using machine learning methods.

The thesis reviews existing approaches to GPS trajectory analysis and user profile construction based on location data. The characteristics of spatio-temporal data and methods for their processing are investigated.

A software tool for user trajectory analysis and user profile construction has been developed. Experimental studies on real-world data were conducted to evaluate the effectiveness of the proposed approach.

The obtained results can be used in user mobility analysis systems, personalization services, and intelligent geographic information systems.

ОГЛАВЛЕНИЕ

1	Построение профиля пользователя по GPS-траекториям	5
1.1	GPS-траектория как объект анализа	5
1.2	Профиль пользователя	6
1.3	Формальная постановка задач построения профиля пользо- вателя	6
1.4	Выводы по главе	8
2	Группировка GPS-траекторий	9
2.1	Требования к представлению траекторий	9
2.2	Подходы к построению представлений траекторий	10
2.2.1	Агрегированные признаки	10
2.2.2	Представления, основанные на сходстве маршрутов .	11
2.2.3	Представления с использованием пользовательской принадлежности	12
2.3	Выбор подхода к построению представлений	13
2.4	Выбор архитектуры модели	14
2.5	Метод построения представлений траекторий	15
2.5.1	Выбор функции потерь	15
2.5.2	Контрастивное обучение представлений траекторий .	16
2.5.3	Формирование входного представления траектории .	17
2.6	Архитектура Transformer-модели	18
2.6.1	Обучение модели и построение пространства пред- ставлений	21
2.6.2	Требования к кластеризации представлений траекторий	21
3	Выявление аномального поведения пользователей	23
3.1	Особенности задачи выявления аномалий	23
3.2	Подходы к выявлению аномалий	23
3.2.1	Статистические методы	23
3.2.2	Методы на основе расстояний и плотности	24
3.2.3	Последовательностные модели	24
3.3	Выбор последовательностной модели	25
3.4	Формирование последовательностей событий	26
3.5	Анализ поведения пользователя	28
3.6	Архитектура модели прогнозирования поведения	29
3.7	Вычисление аномального балла	31
3.8	Выводы по главе	32
4	Экспериментальное исследование	34
4.1	Оценка качества представлений траекторий	34

4.1.1	Описание набора данных и схема разбиения	34
4.1.2	Сравниваемые представления и параметры модели . .	35
4.1.3	Процедура кластеризации и метрики качества	37
4.1.4	Результаты кластеризации траекторий	37
4.1.5	Визуальный анализ пространства представлений . . .	39
4.1.6	Выводы по результатам эксперимента	39
4.2	Оценка качества выявления аномального поведения	40
4.2.1	Цель и сценарий эксперимента	40
4.2.2	Экспериментальные данные для задачи выявления аномалий	41
4.2.3	Формирование контрольных аномалий	42
4.2.4	Сравниваемые модели и калибровка порогов	43
4.2.5	Метрики качества	45
4.2.6	Общие результаты обнаружения аномалий	46
4.2.7	Результаты для отдельных типов аномалий	47
4.2.8	Влияние выбора порога	48
4.2.9	Ограничения эксперимента	49
4.2.10	Выводы по результатам эксперимента	50
4.3	Выводы по главе	50

Список использованных источников

53

Введение

Данные о местоположении пользователей, получаемые с помощью GPS-навигации и мобильных устройств, являются важным источником информации о характере их перемещений. Анализ таких данных позволяет выявлять закономерности поведения пользователей, определять типичные маршруты и обнаруживать отклонения от привычной активности.

Построение профиля пользователя на основе данных о его местоположении является актуальной задачей, находящей применение в системах персонализации, прогнозирования перемещений и обеспечения безопасности. Однако обработка GPS-траекторий осложняется большим объёмом данных, их пространственно-временной природой и разнообразием сценариев поведения пользователей.

Объектом исследования являются GPS-траектории пользователей.

Предметом исследования являются методы машинного обучения для построения профиля пользователя по данным о его местоположении.

Цель работы – разработка и исследование подходов к построению профиля пользователя на основе GPS-траекторий с использованием методов машинного обучения.

Для достижения поставленной цели необходимо решить следующие задачи:

- проанализировать существующие подходы к обработке и анализу GPS-траекторий;
- исследовать методы построения профиля пользователя по данным о его перемещениях;
- разработать программное средство для анализа траекторий пользователей;
- провести экспериментальное исследование на реальных данных;
- оценить эффективность предложенного подхода.

Практическая значимость работы заключается в возможности применения полученных результатов в системах анализа мобильности пользователей и интеллектуальных геоинформационных сервисах.

ГЛАВА 1

Построение профиля пользователя по GPS-траекториям

1.1 GPS-траектория как объект анализа

Источником данных для построения профиля пользователя служат GPS-траектории [1], отражающие историю его перемещений. На основе этих данных можно восстанавливать маршруты, выявлять закономерности поведения и анализировать изменения в привычных сценариях перемещения.

Каждое наблюдение содержит координаты и момент времени регистрации

$$p_i = (\varphi_i, \lambda_i, t_i),$$

где φ_i и λ_i — широта и долгота, а t_i — временная метка.

Упорядоченная последовательность наблюдений образует GPS-траекторию

$$T = (p_1, p_2, \dots, p_n), \quad t_1 < t_2 < \dots < t_n.$$

Длина траектории зависит от продолжительности наблюдения и частоты регистрации координат, поэтому количество точек в разных траекториях может различаться.

По координатам и временным меткам вычисляются дополнительные характеристики движения. Для соседних точек определяются временной интервал, пройденное расстояние, скорость и направление движения [15]. Эти величины используются при анализе траекторий и построении признаков поведения.

Набор траекторий задается множеством

$$\mathcal{T} = \{T_1, T_2, \dots, T_m\},$$

где каждая траектория соответствует отдельному фрагменту наблюдаемо-

го движения.

Временной интервал между соседними измерениями траектории не фиксирован, поэтому между двумя точками могут отсутствовать промежуточные наблюдения. Координаты содержат погрешность позиционирования, из-за которой даже неподвижный пользователь может демонстрировать небольшие смещения на карте. Положение пользователя в текущий момент связано с предыдущими наблюдениями, поэтому траектория не может рассматриваться как набор независимых точек.

1.2 Профиль пользователя

История перемещений содержит информацию не только об отдельных маршрутах, но и о поведении пользователя в целом. По совокупности траекторий можно выделить регулярно посещаемые области, периоды активности, повторяющиеся маршруты и другие устойчивые закономерности. Совокупность таких сведений и является профилем пользователя.

Источником данных для построения профиля служит множество траекторий пользователя

$$\mathcal{T} = \{T_1, T_2, \dots, T_k\}.$$

По мере накопления новых наблюдений профиль уточняется и дополняется. Изменение привычных маршрутов, появление новых областей активности или изменение временных паттернов постепенно меняют представление о характерном поведении пользователя.

Профиль отражает закономерности, проявляющиеся в истории перемещений пользователя, и позволяет рассматривать новые наблюдения в контексте накопленного опыта.

1.3 Формальная постановка задач построения профиля пользователя

Построение профиля пользователя в работе рассматривается как последовательный процесс, состоящий из двух связанных задач.

Первая задача заключается в группировке GPS-траекторий по предполагаемой принадлежности пользователям. Пусть задано множество траекторий

$$\mathcal{T} = \{T_1, T_2, \dots, T_m\}.$$

Требуется построить разбиение

$$\mathcal{C} = \{C_1, C_2, \dots, C_K\},$$

удовлетворяющее условиям

$$C_i \cap C_j = \emptyset, \quad i \neq j,$$

$$\bigcup_{j=1}^K C_j = \mathcal{T}.$$

Результатом группировки должно быть разбиение, при котором траектории одного пользователя образуют отдельную группу.

После формирования пользовательских групп появляется возможность анализировать историю перемещений каждого пользователя отдельно. На этой основе решается вторая задача — выявление отклонений от характерного поведения [11].

Для нового наблюдения x вычисляется аномальный балл

$$A_u(x),$$

характеризующий степень его согласованности с накопленной историей пользователя. Решение принимается путем сравнения этого значения с порогом θ_u :

$$\hat{y}_u(x) = \begin{cases} 0, & A_u(x) \leq \theta_u, \\ 1, & A_u(x) > \theta_u. \end{cases}$$

Значение 0 соответствует наблюдению, согласующемуся с историей пользователя, а значение 1 — отклонению от привычного поведения. В зависимости от используемого метода наблюдением может выступать отдельное событие, фрагмент траектории или траектория целиком.

Связь между задачами заключается в том, что оценка поведения требует информации о конкретном пользователе. Поэтому построению модели поведения предшествует этап группировки траекторий.

1.4 Выводы по главе

GPS-траектория представляет собой последовательность пространственно-временных наблюдений, содержащую информацию о перемещениях пользователя.

Профиль пользователя формируется на основе истории перемещений и отражает устойчивые закономерности поведения. Источником данных для построения профиля служит совокупность траекторий пользователя, содержащая сведения о его пространственной и временной активности.

Построение профиля включает группировку траекторий по пользовательской принадлежности и последующий анализ поведения внутри полученных групп.

ГЛАВА 2

Группировка GPS-траекторий

2.1 Требования к представлению траекторий

Задача группировки GPS-траекторий по принадлежности пользователям требует перейти от исходной последовательности наблюдений к представлению, пригодному для сравнения и последующей кластеризации. Выбор такого представления определяется свойствами самих траекторий и особенностями решаемой задачи.

Следует различать задачи классификации и кластеризации траекторий. В задаче классификации для каждой траектории известен пользователь, а целью является отнесение наблюдения к одному из заранее заданных классов. В задаче кластеризации информация о принадлежности траекторий отсутствует, и требуется самостоятельно выделить группы схожих наблюдений.

GPS-траектория представляет собой последовательность пространственно-временных наблюдений переменной длины. Количество точек зависит от продолжительности регистрации и частоты записи координат, поэтому разные траектории содержат различное число наблюдений. По этой причине представление не должно зависеть от длины исходной последовательности.

При анализе траекторий важен порядок наблюдений. Перемещение пользователя определяется не только набором посещенных областей, но и последовательностью переходов между ними. Две траектории могут содержать одинаковые точки, но различаться порядком их посещения. Следовательно, представление должно сохранять информацию о структуре последовательности.

Для сравнения траекторий и оценки расстояний между ними необходимо сопоставить каждой траектории объект фиксированной размерности [18]. Такое представление позволяет использовать стандартные методы анализа данных независимо от длины исходной последовательности.

В случае, когда идентификаторы пользователей доступны в обучающих данных, они могут служить дополнительным источником информации

о закономерностях поведения. Представление должно учитывать этот обучающий сигнал и формировать пространство, в котором различия между пользователями отражаются в расположении траекторий. В этом случае возникает еще одно требование связанное с переносимостью представления. Полученное пространство должно сохранять информативность не только для пользователей, присутствовавших в обучающих данных, но и для новых пользователей, траектории которых ранее не наблюдались.

С учетом рассмотренных особенностей представление траектории должно удовлетворять следующим требованиям:

1. обрабатывать последовательности переменной длины;
2. сохранять порядок пространственно-временных наблюдений;
3. сопоставлять каждой траектории представление фиксированной размерности;
4. сближать траектории одного пользователя и разделять траектории разных пользователей в пространстве представлений;
5. в случае обучения на размеченных данных сохранять применимость для пользователей, отсутствовавших в обучающей выборке.

Сформулированные требования используются далее для анализа существующих подходов к построению представлений траекторий и выбору метода, применяемого в работе.

2.2 Подходы к построению представлений траекторий

Существует несколько подходов к построению представлений GPS-траекторий. Они различаются объемом сохраняемой информации, способом обработки последовательности и возможностью использовать данные о пользовательской принадлежности. Далее рассматриваются методы, близкие к задаче группировки траекторий по пользователям.

2.2.1 Агрегированные признаки

Наиболее простой подход заключается в замене траектории набором числовых характеристик фиксированной размерности. В качестве призна-

ков могут использоваться продолжительность перемещения, длина маршрута, средняя и максимальная скорость, пространственный охват, время начала движения и другие статистические показатели.

После формирования вектора признаков траектории могут сравниваться между собой с использованием стандартных алгоритмов кластеризации [19, 4, 16].

Преимуществом такого подхода является простота реализации и интерпретируемость получаемых признаков.

Основное ограничение связано с потерей последовательной структуры данных. Агрегирование сохраняет только итоговые характеристики перемещения и не учитывает порядок наблюдений. Две траектории могут иметь близкие значения длины маршрута, продолжительности и скорости, но существенно различаться по характеру перемещений. По этой причине агрегированные признаки плохо подходят для задач, в которых важны пространственно-временные закономерности поведения пользователя.

2.2.2 Представления, основанные на сходстве маршрутов

Существуют методы, в которых представление траектории формируется непосредственно на основе последовательности наблюдений. Вместо заранее заданного набора характеристик модель обучается самостоятельно извлекать признаки, отражающие структуру маршрута.

В таких подходах траектория преобразуется в представление фиксированной размерности, сохраняющее информацию о последовательности посещаемых областей и переходах между ними. Сходство между траекториями определяется расстоянием между полученными представлениями.

Одним из наиболее известных методов данного класса является t2vec [18]. В основе метода лежит архитектура кодировщика-декодировщика, обучаемая на задаче восстановления искаженных траекторий. В процессе обучения формируется пространство представлений, устойчивое к шуму координат и различиям в частоте регистрации наблюдений.

Полученные представления хорошо подходят для поиска похожих маршрутов и сравнения траекторий по характеру перемещения. Однако обучающий сигнал в t2vec определяется сходством самих маршрутов и не учитывает информацию о пользователях. В результате траектории разных пользователей, проходящие через одни и те же области, могут располагать-

ся близко друг к другу в пространстве представлений, тогда как различные сценарии перемещения одного пользователя могут оказаться разделены.

По этой причине методы, ориентированные на сходство маршрутов, не обеспечивают разделение траекторий по пользовательской принадлежности и не могут рассматриваться как самостоятельное решение поставленной задачи.

2.2.3 Представления с использованием пользовательской принадлежности

В задачах Trajectory User Linking (TUL) представление траектории обучается с использованием информации о пользователях. Целью данного направления является выявление закономерностей, позволяющих различать пользователей по их истории перемещений.

Пусть задано множество пользователей

$$U = \{u_1, u_2, \dots, u_K\},$$

а каждой траектории обучающей выборки сопоставлен идентификатор пользователя. В этом случае задача может быть сформулирована как многоклассовая классификация

$$f(T) = u_j, \quad u_j \in U.$$

При таком обучении модель получает возможность учитывать не только посещаемые области, но и временные закономерности, характерные последовательности переходов и другие особенности поведения пользователя.

Одним из представителей данного направления является метод TULVAE [20], основанный на вариационном автоэнкодере. Модель формирует компактное латентное представление траектории и использует пользовательские метки в процессе обучения. Однако основная цель обучения связана с восстановлением входных данных, поэтому расстояния между полученными представлениями не обязательно отражают различия между пользователями.

Другим примером является DeerTUL [21], использующий рекуррентную нейронную сеть для обработки последовательности пространственно-

временных наблюдений. Пользовательская принадлежность включается непосредственно в обучающий сигнал, благодаря чему модель формирует представления, ориентированные на различение пользователей.

Развитие этой идеи представлено в модели AttnTUL [22], где для обработки траекторий используется механизм внимания. Такой подход позволяет учитывать зависимости между удаленными участками последовательности и эффективнее использовать пространственно-временной контекст.

В отличие от предыдущих методов, TUL-подходы используют пользовательскую принадлежность как источник обучающего сигнала. Благодаря этому формируемые представления в большей степени отражают особенности поведения пользователя, что делает данный класс методов самым подходящим для задачи группировки траекторий по пользовательской принадлежности.

2.3 Выбор подхода к построению представлений

Рассмотренные подходы в различной степени удовлетворяют требованиям, сформулированным в разделе 2.1.

Агрегированные признаки позволяют получить представление фиксированной размерности и применять стандартные алгоритмы кластеризации. Однако при таком подходе теряется информация о последовательности наблюдений, что ограничивает возможность учитывать пространственно-временную структуру перемещений.

Методы, основанные на сходстве маршрутов, сохраняют последовательную структуру траектории и формируют компактные представления, пригодные для сравнения. Вместе с тем их обучение ориентировано на сходство самих маршрутов и не использует информацию о пользователях. В результате близость траекторий в пространстве представлений не обязательно соответствует пользовательской принадлежности.

Наиболее близкими к поставленной задаче являются подходы класса TUL. Использование пользовательских меток позволяет формировать представления, учитывающие особенности поведения конкретных пользователей. Вместе с тем большинство существующих решений ориентировано на задачу классификации и предполагает наличие фиксированного набора пользователей на этапе обучения.

Возникает противоречие между требованиями задачи. С одной сторо-

ны, информация о пользовательской принадлежности содержит полезный обучающий сигнал и позволяет учитывать особенности поведения пользователей. С другой стороны, итоговая группировка должна оставаться применимой к траекториям пользователей, отсутствовавших в обучающих данных.

Для разрешения этого противоречия представление траектории целесообразно рассматривать отдельно от задачи классификации пользователей. Пользовательские метки могут использоваться для формирования пространства представлений, отражающего особенности поведения, тогда как кластеризация выполняется после построения представления и не зависит от фиксированного набора классов.

Такой подход позволяет использовать информацию о пользовательской принадлежности при обучении и одновременно сохранять возможность анализа новых пользователей. Следовательно, дальнейшее построение модели необходимо основывать на подходах класса TUL, используя пользовательские метки как источник обучающего сигнала для формирования пространства представлений траекторий.

2.4 Выбор архитектуры модели

После выбора подходов класса TUL необходимо определить архитектуру модели, используемой для построения представлений траекторий.

Траектория представляет собой последовательность пространственно-временных наблюдений переменной длины. Поэтому архитектура должна обрабатывать последовательные данные, учитывать зависимости между элементами траектории и формировать представление фиксированной размерности.

Одним из распространенных решений являются рекуррентные нейронные сети [23, 24]. В данных моделях элементы обрабатываются последовательно, а информация о предыдущих наблюдениях передается через скрытое состояние. Этот подход позволяет учитывать порядок наблюдений и широко применяется при анализе последовательных данных.

Развитием рекуррентных сетей стали архитектуры LSTM и GRU [24, 25], предназначенные для более эффективного сохранения информации на больших временных интервалах. По сравнению с классическими рекуррентными сетями они лучше работают с длительными зависимостями.

ми.

Общим ограничением рекуррентных архитектур является последовательный характер вычислений. Информация между удаленными участками траектории передается через цепочку промежуточных состояний, что усложняет моделирование долгосрочных зависимостей.

Альтернативный подход реализован в архитектуре Transformer [2]. В его основе лежит механизм самовнимания, позволяющий каждой позиции последовательности напрямую взаимодействовать с другими элементами входных данных. Благодаря этому модель получает возможность учитывать как локальные, так и удаленные зависимости между наблюдениями без промежуточной передачи информации через скрытые состояния.

Дополнительным преимуществом Transformer является возможность параллельной обработки последовательности, что упрощает обучение модели на больших объемах данных.

С учетом требований, архитектура Transformer является наиболее подходящим вариантом для построения представлений траекторий. Механизм самовнимания позволяет учитывать пространственно-временной контекст на всем протяжении траектории, а выход кодировщика может использоваться для формирования представления фиксированной размерности.

Полученное представление может применяться для сравнения траекторий и последующей группировки. Вместе с тем выбор архитектуры не определяет, каким образом будут располагаться траектории в пространстве представлений. Эти свойства зависят от обучающего сигнала, используемого при обучении модели.

2.5 Метод построения представлений траекторий

2.5.1 Выбор функции потерь

Выбор архитектуры определяет способ обработки траектории, однако сам по себе не задает свойства формируемого пространства представлений. Расположение траекторий в этом пространстве определяется обучающим сигналом, используемым при обучении модели.

В задачах TUL наиболее распространенным подходом является обучение модели на задаче классификации пользователей [20, 21, 22]. Для этого используется функция потерь кросс-энтропии [10], стимулирующая пра-

вильное определение пользовательской принадлежности траектории.

При таком обучении модель формирует внутренние представления, достаточные для разделения пользователей обучающей выборки. Однако кросс-энтропия не накладывает прямых ограничений на взаимное расположение траекторий во внутреннем пространстве представлений. Траектории одного пользователя могут располагаться на различных расстояниях, если это не влияет на результат классификации.

Для задачи группировки важна не только способность различать пользователей, но и структура самого пространства представлений. Желательно, чтобы траектории одного пользователя образовывали компактные группы, а траектории разных пользователей располагались на расстоянии друг от друга. В этом случае расстояния между представлениями могут использоваться непосредственно при кластеризации.

Одним из способов формирования такой структуры является контрастивное обучение [3]. В его основе лежит сравнение положительных и отрицательных пар объектов. Положительными считаются пары траекторий, принадлежащих одному пользователю, отрицательными — пары траекторий разных пользователей.

В процессе обучения модель стремится уменьшить расстояние между представлениями положительных пар и увеличить расстояние между представлениями отрицательных пар. Пользовательские метки используются для формирования обучающего сигнала, однако после завершения обучения они не требуются для построения представлений новых траекторий.

Использование контрастивного обучения позволяет напрямую связывать пользовательскую принадлежность с геометрией пространства представлений. По этой причине данный подход рассматривается в работе как основной механизм формирования представлений траекторий.

2.5.2 Контрастивное обучение представлений траекторий

Пусть каждой траектории после прохождения кодировщика соответствует представление

$$z_i \in \mathbb{R}^d.$$

Для формирования пространства представлений используются поль-

зовательские метки обучающей выборки. Если две траектории принадлежат одному пользователю, соответствующая пара считается положительной. Траектории разных пользователей образуют отрицательные пары.

Цель обучения заключается в том, чтобы представления положительных пар располагались близко друг к другу, а представления отрицательных пар — на большем расстоянии. В результате траектории одного пользователя должны образовывать компактные группы в пространстве представлений.

Для оценки близости представлений используется косинусное сходство [5]

$$\text{sim}(z_i, z_j) = \frac{z_i^\top z_j}{|z_i||z_j|}.$$

Значение косинусного сходства принадлежит интервалу

$$-1 \leq \text{sim}(z_i, z_j) \leq 1.$$

В процессе обучения каждая траектория рассматривается как опорный объект, для которого известны положительные и отрицательные примеры. Функция потерь минимизируется таким образом, чтобы увеличивать сходство между траекториями одного пользователя и уменьшать сходство между траекториями разных пользователей.

Контрастивное обучение связывает пользовательскую принадлежность траекторий со структурой пространства представлений. После завершения обучения кодировщик применяется к траекториям, для которых пользовательские метки отсутствуют. Полученные представления используются в качестве входных данных для алгоритма кластеризации, выполняющего группировку траекторий без использования информации о пользователях.

2.5.3 Формирование входного представления траектории

Исходная GPS-траектория задается последовательностью координат и временных меток. Перед подачей данных в модель каждое наблюдение преобразуется в набор признаков, характеризующих пространственное положение, время регистрации и параметры движения.

Пространственное положение представляется идентификатором

ячейки, полученным после дискретизации исследуемой территории на области фиксированного размера. Каждой точке траектории сопоставляется ячейка, в которой она расположена.

Для описания временного контекста используются час суток и день недели, соответствующие моменту регистрации наблюдения. Эти признаки позволяют учитывать периодичность поведения пользователя и различать посещения одних и тех же областей в разное время.

Помимо пространственных и временных характеристик используются признаки движения. Для каждого наблюдения вычисляются интервал времени относительно предыдущей точки, скорость перемещения и направление движения. Направление представляется парой величин, соответствующих синусу и косинусу угла движения. Такое представление позволяет избежать разрыва значений при переходе через границу 0° и 360° .

В результате каждому элементу траектории сопоставляется набор признаков

$$x_i = (c_i, h_i, w_i, \Delta t_i, v_i, \sin \alpha_i, \cos \alpha_i),$$

где c_i — идентификатор пространственной ячейки, h_i — час суток, w_i — день недели, Δt_i — интервал времени относительно предыдущего наблюдения, v_i — скорость движения, а α_i — направление перемещения.

Полученная последовательность признаков используется в качестве входных данных модели и служит основой для построения представления траектории.

2.6 Архитектура Transformer-модели

Для построения представлений траекторий используется модель на основе архитектуры Transformer Encoder [2]. На вход модели поступает последовательность наблюдений

$$X = (x_1, x_2, \dots, x_n),$$

где каждому наблюдению соответствует набор пространственных, временных и динамических признаков

$$x_i = (c_i, h_i, w_i, \Delta t_i, v_i, \sin \alpha_i, \cos \alpha_i).$$

Перед подачей в модель непрерывные признаки приводятся к ограниченному диапазону значений. Временные интервалы подвергаются логарифмическому преобразованию, а скорость нормализуется относительно максимального допустимого значения. После этого формируется вектор непрерывных признаков

$$r_i = (\Delta t_i, v_i, \sin \alpha_i, \cos \alpha_i).$$

Для категориальных признаков используются обучаемые эмбединги [10, 26]

$$e_i^{\text{cell}} = E_{\text{cell}}(c_i),$$

$$e_i^{\text{hour}} = E_{\text{hour}}(h_i),$$

$$e_i^{\text{week}} = E_{\text{week}}(w_i).$$

Каждый эмбединг представляет собой вектор размерности d .

Непрерывные признаки преобразуются линейным слоем

$$e_i^{\text{cont}} = f(r_i),$$

где $f(\cdot)$ обозначает линейное преобразование с последующей нелинейной активацией и нормализацией.

Представление наблюдения формируется суммированием всех компонентов

$$e_i = e_i^{\text{cell}} + e_i^{\text{hour}} + e_i^{\text{week}} + e_i^{\text{cont}}.$$

Для учета положения элемента внутри траектории используется позиционное представление [2]

$$p_i,$$

после чего на вход кодировщика поступает последовательность

$$\tilde{e}_i = e_i + p_i.$$

Перед каждой траекторией добавляется специальный служебный токен CLS [27]. Его представление обучается совместно с остальными параметрами модели и используется для формирования итогового описания всей траектории. После добавления служебного токена входная последовательность принимает вид

$$(\text{CLS}, \tilde{e}_1, \tilde{e}_2, \dots, \tilde{e}_n).$$

Полученная последовательность обрабатывается кодировщиком Transformer

$$H = \text{Transformer}(\text{CLS}, \tilde{e}_1, \tilde{e}_2, \dots, \tilde{e}_n),$$

$$H = (h_0, h_1, \dots, h_n)$$

где H выходные представления элементов последовательности.

В качестве представления всей траектории используется выходной вектор служебного токена

$$z = h_0.$$

Полученный вектор проходит дополнительное преобразование проекционной сетью

$$z' = g(z),$$

где $g(\cdot)$ представляет собой двухслойную нейронную сеть.

На заключительном этапе выполняется нормализация [28]

$$\hat{z} = \frac{z'}{\|z'\|}.$$

Вектор $\hat{z}$ используется при вычислении контрастивной функции потерь и рассматривается как итоговое представление траектории в пространстве признаков.

2.6.1 Обучение модели и построение пространства представлений

Построение пространства представлений выполняется в два этапа: обучение кодировщика и получение представлений для последующей кластеризации.

На этапе обучения используются траектории, для которых известна пользовательская принадлежность. Каждая траектория преобразуется в последовательность пространственных, временных и динамических признаков и подается на вход модели.

В результате работы кодировщика каждой траектории сопоставляется векторное представление фиксированной размерности. Пользовательские метки используются для формирования положительных и отрицательных пар, необходимых для вычисления контрастивной функции потерь.

В процессе обучения параметры модели изменяются таким образом, чтобы представления траекторий одного пользователя располагались близко друг к другу, а представления траекторий разных пользователей разделялись в пространстве признаков.

После завершения обучения используется только кодировщик траекторий. Пользовательские метки на этом этапе отсутствуют и не участвуют в дальнейшей обработке данных.

Каждая новая траектория преобразуется обученной моделью в векторное представление

$$z_i \in \mathbb{R}^d.$$

Результатом работы модели является пространство представлений, пригодное для применения алгоритмов кластеризации.

2.6.2 Требования к кластеризации представлений траекторий

После завершения обучения каждая траектория представляется вектором фиксированной размерности. Задача группировки пользователей сводится к кластеризации множества полученных представлений.

В практической постановке число пользователей заранее неизвестно. Следовательно, алгоритм кластеризации не должен требовать предвари-

тельного задания количества кластеров. Кроме того, распределение траекторий в пространстве представлений определяется особенностями данных и не позволяет заранее предполагать форму пользовательских групп.

По этой причине предпочтение следует отдавать методам, способным автоматически определять число кластеров и работать с кластерами произвольной структуры. Дополнительным преимуществом является возможность выделения объектов, не принадлежащих ни одной устойчивой группе, поскольку отдельные траектории могут содержать редкие или аномальные сценарии перемещения.

К числу алгоритмов, удовлетворяющих данным требованиям, относятся DBSCAN и HDBSCAN [16, 17]. Оба метода основаны на анализе плотности распределения объектов в пространстве признаков и позволяют выделять кластеры без предварительного задания их количества. В отличие от DBSCAN, алгоритм HDBSCAN способен учитывать различия в плотности кластеров и, как правило, демонстрирует более устойчивые результаты на неоднородных данных.

ГЛАВА 3

Выявление аномального поведения пользователей

3.1 Особенности задачи выявления аномалий

Под аномальным поведением будем понимать наблюдения, характеристики которых отличаются от закономерностей, присутствующих в истории пользователя [11]. Для GPS-данных такие отклонения могут проявляться в виде появления новых маршрутов, посещения ранее нехарактерных областей или изменения времени активности. Поведение пользователя может изменяться со временем, а возможные варианты отклонений не ограничены фиксированным набором сценариев.

Еще одна особенность связана с последовательной структурой данных. Оценка поведения определяется не только отдельными событиями, но и их порядком. Одно и то же посещение локации может быть привычным в рамках регулярного маршрута и необычным в другой последовательности действий. Поэтому при выявлении аномалий необходимо учитывать контекст предыдущих наблюдений.

3.2 Подходы к выявлению аномалий

Существует несколько подходов к выявлению аномального поведения [11]. Они различаются используемым представлением данных, способом оценки отклонений и типом обнаруживаемых аномалий. Далее рассматриваются методы, наиболее близкие к задаче анализа поведения пользователей на основе истории перемещений.

3.2.1 Статистические методы

Одним из наиболее простых подходов является использование статистических характеристик наблюдаемых данных. В этом случае для каждого признака определяется характерный диапазон значений, а отклонения выявляются по степени удаления от типичного поведения.

Для оценки аномальности могут использоваться средние значения, дисперсии, квантили распределения и другие статистические показатели. Наблюдения, существенно отличающиеся от основной массы данных, рассматриваются как потенциальные аномалии.

Преимуществом статистических методов является простота реализации и интерпретации результатов. Однако такие методы обычно анализируют признаки независимо друг от друга и плохо учитывают структуру поведения пользователя во времени.

Для задач анализа GPS-траекторий это ограничение является существенным, поскольку отклонение может проявляться не в отдельных характеристиках наблюдения, а в последовательности действий пользователя.

3.2.2 Методы на основе расстояний и плотности

Другой класс методов основан на анализе взаимного расположения наблюдений в пространстве признаков. Предполагается, что нормальное поведение образует области высокой плотности, тогда как аномальные наблюдения располагаются изолированно от основной массы данных.

К данной группе относятся методы ближайших соседей, Local Outlier Factor (LOF), Isolation Forest и другие алгоритмы обнаружения выбросов [29, 30, 31].

Общим преимуществом таких методов является отсутствие необходимости задавать явное описание аномалий. Решение принимается на основе структуры данных и взаимного расположения наблюдений.

Вместе с тем большинство методов данного класса рассматривает наблюдения как независимые объекты. Последовательность событий и временные зависимости между ними в явном виде не учитываются. По этой причине методы на основе расстояний и плотности ограниченно применимы к анализу пользовательского поведения, представленного в виде последовательности действий.

3.2.3 Последовательностные модели

В задачах анализа поведения пользователя важную роль играет порядок возникновения событий. Одни и те же действия могут встречаться регулярно, однако изменение их последовательности способно свидетельствовать об отклонении от привычного сценария.

Для учета подобных зависимостей используются последовательностные модели. К ним относятся марковские модели, рекуррентные нейронные сети и архитектуры, основанные на механизме внимания [32, 24, 25, 2].

Общая идея таких методов заключается в построении модели нормального поведения пользователя на основе исторических данных. После обучения модель оценивает вероятность наблюдаемых событий или прогнозирует дальнейшее развитие последовательности. Снижение вероятности наблюдаемого поведения может служить признаком аномалии.

По сравнению со статистическими методами и методами на основе расстояний последовательностные модели позволяют учитывать контекст наблюдений и зависимости между событиями, возникающими на различных участках истории пользователя.

3.3 Выбор последовательностной модели

Рассмотренные методы обладают различными возможностями и ориентированы на разные типы данных. Статистические методы и методы, основанные на анализе расстояний, используют отдельные наблюдения или заранее сформированные признаки. Такой подход позволяет выявлять выбросы по значениям характеристик, однако не учитывает порядок возникновения событий.

В задаче анализа пользовательского поведения последовательность наблюдений содержит не меньше информации, чем сами наблюдения. Поведение пользователя формируется в виде повторяющихся сценариев, состоящих из связанных между собой действий. Нарушение такого сценария может проявляться даже в том случае, когда каждое отдельное событие ранее встречалось в истории наблюдений.

По этой причине наибольший интерес представляют последовательностные модели, способные учитывать зависимости между событиями. В отличие от методов, работающих с независимыми наблюдениями, такие модели анализируют поведение пользователя как единую последовательность и позволяют оценивать согласованность новых событий с ранее наблюдавшимися сценариями.

Одним из распространенных подходов к анализу последовательностей является прогнозирование следующего элемента по предыдущему контексту. В процессе обучения модель получает последовательность событий

пользователя и учится предсказывать наиболее вероятное продолжение. Если наблюдаемое событие оказывается маловероятным с точки зрения накопленной истории, оно может рассматриваться как потенциальное отклонение от нормального поведения.

Для реализации такого подхода могут использоваться рекуррентные нейронные сети, их модификации LSTM и GRU, а также архитектуры на основе механизма самовнимания [24, 25, 2]. Рекуррентные модели учитывают порядок наблюдений за счет последовательной передачи скрытого состояния между соседними элементами. Однако при увеличении длины последовательности информация о ранних событиях проходит через большое число промежуточных состояний, что затрудняет моделирование долгосрочных зависимостей.

Альтернативой является архитектура Transformer, в которой взаимодействие между элементами последовательности реализуется через механизм самовнимания. Каждое событие может напрямую учитывать информацию от других событий независимо от расстояния между ними в последовательности. Это позволяет эффективно моделировать как локальные, так и долгосрочные зависимости поведения пользователя.

С учетом рассмотренных особенностей для выявления аномального поведения в работе используется подход, основанный на прогнозировании последовательности событий с помощью архитектуры Transformer. Аномальность наблюдения определяется степенью согласованности фактически наблюдаемого события с прогнозом модели, построенным на основе предшествующего поведения пользователя.

3.4 Формирование последовательностей событий

Непосредственное использование GPS-координат в качестве входных данных для модели выявления аномалий не возможно из-за большого числа возможных значений и наличия погрешностей позиционирования. Кроме того, отдельные координаты слабо отражают характер действий пользователя и не позволяют напрямую анализировать закономерности поведения. Поэтому перед обучением модели траектории преобразуются в последовательности событий. Каждое событие описывает действие пользователя, связанное с перемещением между пространственными зонами или пребыванием внутри некоторой зоны.

Предварительно пространство наблюдений разбивается на дискретные области. Каждой области сопоставляется уникальный идентификатор зоны. После этого траектория представляется последовательностью сегментов двух типов:

- пребывание пользователя в зоне;
- перемещение между зонами.

Для сегмента пребывания событие определяется идентификатором посещаемой зоны. Для сегмента перемещения событие задается парой зон, соответствующих началу и окончанию перемещения.

Одного пространственного описания недостаточно для анализа поведения пользователя. Одни и те же действия могут иметь различную интерпретацию в зависимости от времени их выполнения. По этой причине в описание события дополнительно включается временной контекст.

Для каждого события определяются:

- временной интервал суток;
- день недели;
- признак выходного дня.

Временной интервал суток задается дискретной категорией, характеризующей момент возникновения события. Такое представление позволяет учитывать различия между утренней, дневной, вечерней и ночной активностью пользователя.

После добавления пространственных и временных характеристик каждое событие может быть представлено в виде

$$s_i = (e_i, z_i^{\text{from}}, z_i^{\text{to}}, b_i, w_i, h_i),$$

где

- | | |
|---|--|
| e_i | — тип события; |
| z_i^{from} и z_i^{to} | — идентификаторы начальной и конечной зон; |
| b_i | — временной интервал суток; |
| w_i | — номер дня недели; |
| h_i | — признак выходного дня. |

Полученная последовательность событий

$$S = (s_1, s_2, \dots, s_n)$$

сохраняет информацию о пространственном положении пользователя, времени событий и порядке их следования.

Для последующей обработки события преобразуются в дискретные токены. Каждой уникальной комбинации характеристик сопоставляется собственный идентификатор словаря. В результате история поведения пользователя представляется последовательностью токенов

$$X = (x_1, x_2, \dots, x_n),$$

где x_i соответствует событию s_i .

Такое представление позволяет рассматривать историю поведения пользователя как последовательность символов фиксированного словаря и применять методы моделирования последовательностей, используемые в задачах обработки естественного языка.

3.5 Анализ поведения пользователя

Представление поведения пользователя в виде последовательности событий используется не только для выявления аномалий. Такое описание сохраняет информацию о пространственной активности пользователя и порядке возникновения событий, что позволяет анализировать закономерности поведения.

Каждое событие содержит сведения о посещаемой области, перемещении между областями и временном контексте. В результате последовательность событий отражает историю действий пользователя в более компактной форме по сравнению с исходными GPS-наблюдениями.

На основе последовательностей событий могут определяться наиболее часто посещаемые зоны пользователя. Частота появления соответствующих событий позволяет выделять области, регулярно присутствующие в его истории перемещений.

Анализ последовательностей также дает возможность выявлять наиболее распространенные переходы между зонами. Такие переходы харак-

теризуют типичные направления перемещений пользователя и позволяют описывать структуру его активности.

Дополнительный интерес представляет поиск повторяющихся последовательностей событий. Наличие регулярно встречающихся подпоследовательностей может свидетельствовать о существовании устойчивых сценариев поведения, соответствующих привычным маршрутам или повторяющимся действиям пользователя.

Включение временных характеристик в описание событий позволяет анализировать закономерности активности в различные периоды суток и дни недели. Это дает возможность выявлять не только пространственные, но и временные паттерны поведения.

Таким образом, последовательность событий может рассматриваться как компактное описание пользовательского поведения, пригодное как для выявления аномалий, так и для извлечения характеристик, формирующих профиль пользователя.

3.6 Архитектура модели прогнозирования поведения

Полученная последовательность токенов используется для обучения модели прогнозирования поведения пользователя. Задача модели заключается в оценке вероятности появления следующего события на основе предшествующего контекста.

Пусть история поведения пользователя представлена последовательностью токенов

$$X = (x_1, x_2, \dots, x_n).$$

Для каждого положения t модель получает последовательность предыдущих событий

$$(x_1, x_2, \dots, x_{t-1})$$

и должна предсказать токен x_t .

Каждый токен сначала преобразуется в векторное представление фиксированной размерности с помощью слоя эмбедингов [10, 26]. Пусть словарь событий содержит V уникальных токенов. Тогда каждому токenu x_i сопоставляется вектор

$$e_i \in \mathbb{R}^d,$$

где d — размерность пространства эмбеддингов.

Поскольку архитектура Transformer [2] не учитывает порядок элементов последовательности автоматически, к эмбеддингам событий добавляются позиционные представления

$$h_i = e_i + p_i,$$

где p_i — позиционный эмбеддинг для позиции i .

Полученная последовательность векторов поступает на вход кодировщика Transformer. Основным элементом архитектуры является механизм самовнимания, позволяющий каждому событию учитывать информацию о предыдущих событиях последовательности.

Для предотвращения использования информации о будущих событиях применяется причинная маска (causal mask). Благодаря этому при прогнозировании токена x_t модель имеет доступ только к событиям

$$x_1, \dots, x_{t-1}.$$

Результатом работы кодировщика является последовательность скрытых представлений

$$H = (h_1, h_2, \dots, h_n).$$

Для каждой позиции вычисляется распределение вероятностей по словарю событий

$$P(x_t \mid x_1, \dots, x_{t-1}).$$

Тем самым модель формирует прогноз следующего события на основе всей предшествующей истории поведения пользователя.

Обучение выполняется по размеченной последовательности событий. Для каждого положения последовательности правильным ответом служит фактически наблюдаемое следующее событие. В качестве функции потерь используется кросс-энтропия

$$\mathcal{L} = - \sum_{t=1}^n \log P(x_t \mid x_1, \dots, x_{t-1}).$$

Минимизация данной функции приводит к увеличению вероятности событий, соответствующих наблюдаемому поведению пользователя.

После завершения обучения модель формирует вероятностное описание характерных последовательностей событий. Это позволяет использовать вероятность наблюдаемых событий для оценки их соответствия ранее зафиксированным закономерностям поведения.

3.7 Вычисление аномального балла

После обучения модель формирует распределение вероятностей появления следующего события на основе предшествующего контекста. Для каждой позиции последовательности Transformer вычисляет вероятность

$$P(x_t \mid x_1, \dots, x_{t-1}),$$

характеризующую согласованность наблюдаемого события с ранее встречавшимися сценариями поведения пользователя.

Если событие соответствует закономерностям, присутствующим в обучающих данных, модель присваивает ему высокую вероятность. Напротив, редкие или ранее не встречавшиеся события получают низкие вероятности. Это свойство позволяет использовать прогноз модели для выявления отклонений от привычного поведения.

Для оценки аномальности события используется отрицательный логарифм вероятности [10, 11]

$$a_t = -\log P(x_t \mid x_1, \dots, x_{t-1}).$$

Такая величина обладает двумя полезными свойствами. Во-первых, значение аномального балла возрастает при уменьшении вероятности наблюдаемого события. Во-вторых, логарифмическое преобразование позволяет уменьшить влияние больших различий между вероятностями.

Малые значения a_t соответствуют событиям, хорошо согласующимся с историей поведения пользователя. Большие значения указывают на события, которые модель считает маловероятными.

Поскольку отдельные ошибки прогнозирования могут возникать и для нормального поведения, оценка выполняется не по одному событию, а по последовательности событий. Для последовательности длины n вычисляется средний аномальный балл

$$A = \frac{1}{n} \sum_{t=1}^n a_t.$$

Полученная величина характеризует степень соответствия наблюдаемой последовательности ранее изученным закономерностям поведения.

Для принятия решения используется пороговое значение θ

$$\hat{y} = \begin{cases} 0, & A \leq \theta, \\ 1, & A > \theta. \end{cases}$$

Значение 0 соответствует нормальному поведению, а значение 1 интерпретируется как обнаруженная аномалия.

Использование вероятностной оценки позволяет выявлять не только полностью новые события, но и нарушения привычных последовательностей действий. Даже если отдельные события ранее встречались в истории пользователя, их необычное сочетание может приводить к снижению прогнозируемой вероятности и увеличению аномального балла.

3.8 Выводы по главе

Рассмотрена задача выявления аномального поведения пользователя на основе истории его перемещений. Показано, что отклонения могут проявляться не только в появлении новых событий, но и в нарушении характерных последовательностей действий, поэтому при анализе необходимо учитывать порядок наблюдений и их контекст.

Проведен обзор основных подходов к выявлению аномалий. Рассмотрены статистические методы, методы на основе расстояний и плотности, а также последовательностные модели. По результатам анализа выбран подход, основанный на моделировании последовательности пользовательских событий.

Для описания поведения пользователя предложено представление в виде последовательности событий, включающих пространственные и вре-

менные характеристики активности. Такое представление позволяет сохранять информацию о посещаемых областях, переходах между ними и временных закономерностях поведения. Кроме выявления аномалий, последовательности событий могут использоваться для анализа пользовательских паттернов и формирования характеристик профиля пользователя.

В качестве модели прогнозирования поведения выбрана архитектура Transformer. Модель обучается предсказывать следующее событие по предшествующему контексту и формирует вероятностное описание характерных сценариев поведения пользователя.

Оценка аномальности выполняется на основе вероятности наблюдаемых событий. Для каждого события вычисляется аномальный балл, отражающий степень его согласованности с ранее наблюдавшимися сценариями поведения. Полученные оценки используются для выявления отклонений от характерного поведения пользователя.

ГЛАВА 4

Экспериментальное исследование

Целью экспериментального исследования является проверка применимости предложенных методов к двум задачам построения профиля пользователя по GPS-траекториям. В первой части главы оценивается качество векторных представлений траекторий, используемых для группировки пользователей. Во второй части исследуется качество выявления аномального поведения на основе последовательностей событий пользователя.

Эксперименты проводились на наборе данных GeoLife GPS Trajectories [1], содержащем реальные GPS-наблюдения пользователей. Использование реальных траекторий позволяет учитывать неравномерную частоту регистрации координат, различную продолжительность наблюдений и неоднородность индивидуальных сценариев мобильности.

В данной главе не повторяются алгоритмические детали формирования признаков, токенизации и архитектур моделей, рассмотренные в главах 2 и 3. Основное внимание уделяется экспериментальной постановке, параметрам выборок, конфигурациям обучения, метрикам качества и анализу полученных результатов.

4.1 Оценка качества представлений траекторий

4.1.1 Описание набора данных и схема разбиения

Для оценки качества построения представлений использовался набор данных GeoLife GPS Trajectories. В исходных файлах для каждой точки траектории заданы широта, долгота и временная метка. Перед обучением выполнялась очистка некорректных записей, разбиение исходной истории перемещений на отдельные траектории и преобразование координат в дискретные пространственные токены по процедуре, описанной в главе 2.

Проверялась не только способность модели различать пользователей обучающей выборки, но и переносимость полученного пространства представлений на новых пользователей. Поэтому использовалось разбиение по

пользователям:

$$U_{train} \cap U_{test} = \emptyset.$$

Все траектории тестовых пользователей полностью исключались из обучения и валидации. Валидационная выборка формировалась только из данных пользователей обучающей части и применялась для контроля обучения и выбора сохраненного состояния модели.

На этапе тестирования пользовательские метки не использовались при построении представлений и кластеризации. Они применялись только после кластеризации для расчета внешних метрик качества. Параметры разбиения приведены в таблице 4.1.

Таблица 4.1: Параметры эксперимента по группировке траекторий

Параметр	Значение
Пользователи в обучающей выборке	114
Траектории в обучающей выборке	107349
Пользователи в тестовой выборке	29
Траектории в тестовой выборке	28594
Число кластеров на этапе оценки	29

Число кластеров задавалось равным числу пользователей в тестовой выборке. В данной постановке это значение используется только для проверки качества пространства признаков. Если представления информативны, то при заданном числе кластеров траектории одного пользователя должны группироваться совместно.

4.1.2 Сравнимые представления и параметры модели

В эксперименте сравнивались два способа преобразования траектории в вектор фиксированной размерности.

Первый способ использовался как базовый. Для каждой траектории рассчитывался набор агрегированных характеристик: продолжительность, длина маршрута, показатели скорости, пространственный охват и временные признаки начала движения. Такой подход не использует последовательную структуру маршрута и служит нижней границей качества.

Второй способ основан на Transformer Encoder . На вход модели подавалась последовательность пространственных токенов. К последователь-

ности добавлялся служебный токен, состояние которого после обработки использовалось как embedding всей траектории:

$$z(T) \in \mathbb{R}^{128}.$$

Основные параметры модели и обучения приведены в таблице 4.2.

Таблица 4.2: Конфигурация Transformer-модели для построения представлений

Параметр	Значение
Размерность embedding-вектора	128
Максимальная длина входной последовательности	256 токенов
Число слоев Transformer Encoder	3
Число голов самовнимания	4
Размер внутреннего полносвязного слоя	256
Dropout	0,1
Оптимизатор	AdamW
Размер mini-batch	64
Скорость обучения	$3 \cdot 10^{-4}$
Weight decay	10^{-4}
Максимальное число эпох	40
Температура контрастивной функции потерь	0,1
Ограничение нормы градиента	1,0
Коэффициент контрастивного слагаемого λ_{SC}	0,5

Функция потерь включала классификационную и контрастивную составляющие:

$$\mathcal{L} = \mathcal{L}_{CE} + \lambda_{SC}\mathcal{L}_{SC}.$$

Классификационная часть способствовала разделению пользователей обучающей выборки, а supervised contrastive loss [3] дополнительно формировал геометрию embedding-пространства: сближал представления траекторий одного пользователя и отдалял представления траекторий разных пользователей.

Обучение модели выполнялось на персональном компьютере с процессором Intel Core i7-1065G7, 8 ГБ оперативной памяти и графическим

ускорителем NVIDIA GeForce MX330. Средняя продолжительность одной эпохи составляла около 20 минут. Полное время обучения при максимальном числе эпох составило приблизительно 13 часов.

4.1.3 Процедура кластеризации и метрики качества

После завершения обучения параметры Transformer фиксировались. Для каждой траектории тестовой выборки вычислялся embedding-вектор без использования пользовательской метки. Далее полученные векторы кластеризовались.

Для Transformer-представлений применялась агломеративная кластеризация со средней связью и косинусной мерой расстояния [4, 5]. Для агрегированных признаков использовалась та же схема кластеризации. Итоговый сценарий оценки включал следующие шаги:

1. обучить Transformer только на пользователях обучающей выборки;
2. зафиксировать параметры модели;
3. вычислить представления всех траекторий тестовых пользователей;
4. выполнить кластеризацию тестовых представлений при $K = 29$;
5. сравнить полученные кластеры с истинной пользовательской принадлежностью траекторий.

Для количественной оценки использовались Adjusted Rand Index (ARI) и Normalized Mutual Information (NMI) [6, 7]. ARI показывает согласованность пар объектов в истинном и предсказанном разбиении с поправкой на случайное совпадение. NMI оценивает долю информации о пользовательской принадлежности, сохраненную в полученном разбиении. Значение 1 для обеих метрик соответствует полному совпадению кластеров с пользователями, а значения, близкие к нулю, соответствуют слабой связи между кластеризацией и истинными метками.

4.1.4 Результаты кластеризации траекторий

Результаты кластеризации тестовых траекторий пользователей, отсутствовавших при обучении, приведены в таблице 4.3.

Таблица 4.3: Результаты кластеризации тестовых траекторий

Метод	ARI	NMI
Агрегированные признаки	0,0300	0,1280
Transformer	0,2648	0,2077

Агрегированные признаки получили значение $ARI = 0,0300$. Этот результат близок к случайному уровню и показывает, что общие характеристики траектории, такие как длительность, длина пути, средняя скорость и пространственный охват, недостаточны для устойчивого разделения пользователей в рассматриваемой постановке. Такие признаки описывают траекторию в целом, но почти не отражают порядок посещения конкретных пространственных областей.

Transformer-представления обеспечили значение

$$ARI = 0,2648, \quad NMI = 0,2077.$$

По сравнению с агрегированными признаками ARI увеличился на

$$0,2648 - 0,0300 = 0,2348,$$

а NMI увеличился на

$$0,2077 - 0,1280 = 0,0797.$$

Таким образом, на тестовых пользователях, отсутствовавших при обучении, Transformer формирует более информативное пространство представлений, чем базовый набор агрегированных характеристик.

Важно, что полученный результат нельзя объяснить запоминанием обучающих пользователей: все траектории тестовых пользователей были исключены из обучения. Следовательно, модель выделяет признаки, частично переносимые на новые истории перемещения. К таким признакам относятся характерные последовательности посещаемых областей, повторяемые маршруты и пространственная структура перемещения внутри траектории.

При этом значения метрик остаются существенно ниже единицы. Это означает, что построенное пространство представлений не восстанавливает

пользовательскую принадлежность полностью. Такое поведение ожидаемо для сценария с новыми пользователями, поскольку модель не обучалась непосредственно на их индивидуальных маршрутах.

4.1.5 Визуальный анализ пространства представлений

Для дополнительной проверки структуры embedding-пространства была выполнена двумерная визуализация тестовых траекторий методом UMAP. В визуализацию включались только траектории пользователей тестовой выборки.

Рисунок 4.1 – Визуализация пространства представлений траекторий методом UMAP

Для агрегированных признаков точки различных пользователей существенно перекрываются. Это согласуется с низким значением $ARI = 0,0300$: в таком пространстве траектории разных пользователей имеют близкие значения общих характеристик и не образуют устойчивых пользовательских групп.

Для Transformer-представлений визуальная структура выражена сильнее: появляются локальные области, в которых сосредоточены траектории одного пользователя или небольшой группы пользователей. Это соответствует увеличению ARI и NMI в таблице 4.3. Одновременно на визуализации сохраняются зоны смешения классов, что объясняет, почему значения метрик остаются далекими от 1.

Таким образом, визуальный анализ подтверждает результаты кластеризации: Transformer делает пространство траекторий более структурированным.

4.1.6 Выводы по результатам эксперимента

Проведенный эксперимент показал, что Transformer Encoder формирует более информативные представления GPS-траекторий, чем базовый подход на основе агрегированных признаков. При разбиении по пользователям модель не получает траектории тестовых пользователей во время обучения, однако ее embedding-пространство все равно лучше согласуется с истинной пользовательской принадлежностью.

Значение ARI увеличилось с 0,0300 для агрегированных признаков до 0,2648 для Transformer, а NMI - с 0,1280 до 0,2077. Это подтверждает, что

последовательная структура траектории содержит информацию, полезную для построения пользовательского профиля, а Transformer способен извлекать эту информацию из дискретизированных GPS-последовательностей.

4.2 Оценка качества выявления аномального поведения

4.2.1 Цель и сценарий эксперимента

Цель второй части экспериментального исследования состоит в проверке того, насколько модель поведения пользователя позволяет выявлять события, не согласующиеся с его предшествующей историей перемещений. В отличие от первой задачи, где анализировались траектории разных пользователей, здесь каждый пользователь рассматривается независимо, а объектом оценки является отдельное событие в его хронологической последовательности.

В исходном наборе GeoLife отсутствует разметка реального аномального поведения. Поэтому качество оценивалось с использованием контролируемой схемы: модели обучались и калибровались только на реальных немодифицированных последовательностях, а в тестовую часть вносились заранее известные изменения. Такой подход позволяет сохранить реальные маршруты и временную структуру данных, но при этом получить положительный класс для расчета метрик.

Для каждого пользователя история наблюдений упорядочивалась по времени и делилась по календарным дням на три последовательные части:

60% - обучение, 20% - калибровка, 20% - тестирование.

Случайное перемешивание дней не выполнялось. Обучающая часть использовалась для построения модели поведения, калибровочная - для выбора порога оценки аномальности, тестовая - для итоговой оценки качества.

Итоговый сценарий эксперимента имел следующий вид:

1. для выбранного пользователя взять хронологически упорядоченные последовательности событий, сформированные по процедуре главы 3;
2. разделить дни наблюдения на обучающую, калибровочную и тестовую части;

3. обучить сравниваемые модели только на обучающей части;
4. вычислить аномальные быллы на калибровочной части и зафиксировать пороги;
5. внести контрольные аномалии в тестовую часть;
6. рассчитать оценки нормальных и измененных событий без подбора порога по тестовой разметке;
7. вычислить PR-AUC и recall при зафиксированном пороге.

4.2.2 Экспериментальные данные для задачи выявления аномалий

Для второй задачи использовались готовые последовательности событий, построенные из GPS-наблюдений по алгоритму главы 3. Правила выделения событий, пространственной дискретизации и токенизации здесь повторно не приводятся; в эксперименте фиксируются только характеристики полученной выборки и схема ее использования.

В эксперимент были включены три пользователя GeoLife: 002, 030 и 085. Они различаются по продолжительности наблюдений, числу посещенных зон и объему сформированных событий, что позволяет проверить устойчивость подхода при разных типах индивидуальной мобильности. Основные характеристики подготовленных последовательностей приведены в таблице 4.4.

Таблица 4.4: Характеристики данных для анализа аномального поведения

Пользователь	GPS-точки	Активные дни	События	Зоны	Период наблюдений
002	248217	118	19930	2638	23.10.2008–22.03.2009
030	615948	185	58730	3832	13.01.2009–29.07.2009
085	601871	291	65077	5233	13.02.2008–28.09.2009

Хронологическое разделение историй пользователей представлено в таблице 4.5.

Таблица 4.5: Хронологическое разделение историй пользователей

Пользователь	Обучение		Калибровка		Тестирование	
	Дни	События	Дни	События	Дни	События
002	70	13008	24	4403	24	2519
030	111	37983	37	10356	37	10391
085	174	29607	58	14203	59	21267

Обучающие, калибровочные и тестовые дни не пересекаются. Такое разделение соответствует практическому сценарию, в котором профиль пользователя строится по прошлой истории, затем на отдельном историческом промежутке настраивается чувствительность модели, а новые события оцениваются только после этого.

4.2.3 Формирование контрольных аномалий

Поскольку в исходных данных нет истинной разметки аномального поведения, в тестовые последовательности вносились контролируемые изменения. Исходное событие сохранялось как нормальное наблюдение с меткой 0, а его измененная копия добавлялась в контрольную выборку с меткой 1. В рамках одного запуска одно и то же положение тестовой последовательности не использовалось для нескольких типов аномалий.

Рассматривались четыре типа отклонений:

1. *нетипичная пространственная зона*: событие переносилось в зону, отсутствующую в обучающей истории пользователя;
2. *нетипичное время события*: пространственная часть события сохранялась, но временной интервал заменялся на нехарактерный;
3. *редкий переход между зонами*: использовались известные пользователю зоны, но создавался переход, не соответствующий обучающей истории;
4. *нарушение последовательного контекста*: в позицию помещалось событие, компоненты которого встречались ранее, но его появление после текущей предыстории было нетипичным.

Первые три типа проверяют чувствительность модели к пространственным и временным отклонениям. Четвертый тип особенно важен для

оценки последовательной модели, поскольку отдельное событие может выглядеть допустимым по своим компонентам, но быть необычным именно в текущем контексте.

Целевое количество контрольных аномалий задавалось равным 5% от числа тестовых событий и распределялось равномерно между четырьмя типами. Фактическое число аномалий в одном запуске приведено в таблице 4.6.

Таблица 4.6: Количество контрольных аномалий в одном запуске

Пользователь	Тестовые события	На тип	Всего	Доля, %
002	2519	31	124	4,69
030	10391	130	520	4,77
085	21267	265	1060	4,75

Чтобы снизить зависимость результатов от случайного выбора позиций и конкретных значений модификаций, формирование контрольной выборки повторялось для десяти начальных состояний генератора:

$$seed \in \{2026, 2027, \dots, 2035\}.$$

Модели обучались один раз для каждого пользователя. При повторных запусках изменялись только позиции внесения аномалий и конкретные варианты замен.

4.2.4 Сравнимые модели и калибровка порогов

В эксперименте сравнивались две модели: вероятностная частотная модель с механизмом backoff [9] и нейросетевая модель на основе Transformer .

Вероятностная модель использовалась как базовый способ сравнения. Она оценивала вероятность события по частотам, накопленным в обучающей истории пользователя. Если точный контекст события отсутствовал, модель переходила к более общему уровню оценки: сначала к вероятности события во временном контексте, затем к глобальной частоте события. Для всех уровней применялось аддитивное сглаживание с параметром $\alpha = 1$.

Transformer использовался как последовательная модель, способная учитывать более длинную предысторию событий. Модель обучалась пред-

сказывать следующий токен по предыдущему контексту длиной до 96 событий. При обучении применялась causal mask, исключающая использование будущей информации. Основные параметры приведены в таблице 4.7.

Таблица 4.7: Параметры Transformer-модели для выявления аномалий

Параметр	Значение
Длина контекста	96
Размерность скрытого состояния	128
Число слоев Transformer Encoder	4
Число голов внимания	4
Размер внутреннего полносвязного слоя	512
Dropout	0,15
Минимальная частота токена в словаре	1
Размер mini-batch	64
Скорость обучения	$5 \cdot 10^{-4}$
Weight decay	10^{-2}
Ограничение нормы градиента	1,0
Максимальное число эпох	40
Критерий ранней остановки	5 эпох
Доля валидационных дней внутри обучающей части	15%
Начальное состояние генератора	42

Для обеих моделей оценка аномальности задавалась отрицательным логарифмом вероятности наблюдаемого события [10, 11]:

$$A(e_t) = -\log P(e_t \mid context_t).$$

Чем ниже вероятность события в данном контексте, тем выше значение оценки аномальности.

Порог обнаружения определялся по распределению оценки на калибровочной части:

$$\theta = Q_{0,99}(\mathcal{A}_{cal}),$$

где $\mathcal{A}_{cal}$ - множество оценок событий калибровочного периода. Порог не подбирался по тестовым аномалиям, что соответствует постановке без размеченных примеров отклонений.

Параметры, полученные при обучении и калибровке, приведены в таблице 4.8.

Таблица 4.8: Результаты обучения и калибровки моделей

Пользователь	Словарь	Эпоха	Время, мин	θ_{prob}	θ_{tr}
002	1768	8	6,4	8,6913	12,3753
030	5175	7	21,9	9,5590	14,2239
085	3882	5	12,5	9,2165	10,1707

Ранняя остановка сработала для всех трех пользователей. Наилучшее состояние Transformer было достигнуто не позднее восьмой эпохи, поэтому ограничение в 40 эпох не приводило к избыточному продолжению обучения.

4.2.5 Метрики качества

Положительным классом в эксперименте являлось искусственно измененное событие. Для итоговой оценки использовались две метрики: PR-AUC и recall. Такой выбор позволяет отдельно оценить качество ранжирования событий по степени аномальности и практическую способность модели обнаруживать внесенные отклонения при заранее выбранном пороге.

PR-AUC вычислялся как площадь под PR-кривой по всем тестовым событиям. Метрика характеризует качество выделения положительного класса в верхней части ранжированного списка и особенно важна при дисбалансе классов. В общей контрольной выборке доля аномалий составляет около 4,7%, поэтому случайный уровень PR-AUC близок к 0,047.

Recall рассчитывался после применения порога, выбранного по калибровочной части:

$$Recall = \frac{TP}{TP + FN}.$$

Эта метрика показывает, какая доля внесенных аномалий была обнаружена моделью. В данной задаче recall выбран как основная пороговая метрика, поскольку пропуск аномального события является более существенным недостатком, чем получение избыточного числа срабатываний на этапе предварительного обнаружения отклонений.

Для каждого пользователя метрики рассчитывались по десяти вариантам формирования контрольной выборки. В таблицах приводится среднее значение и стандартное отклонение:

$$\overline{M} \pm \sigma_M.$$

4.2.6 Общие результаты обнаружения аномалий

Значения PR-AUC и recall для трех пользователей приведены в таблице 4.9. Вероятностная модель в этом эксперименте использовалась как базовый способ сравнения: она позволяет оценить, насколько хорошо аномалии выявляются с помощью частот событий и короткого контекста без нейросетевого моделирования последовательности.

Таблица 4.9: PR-AUC и recall для задачи выявления аномалий

Пользователь	Модель	PR-AUC	Recall
002	Вероятностная	$0,0641 \pm 0,0087$	$0,0153 \pm 0,0084$
002	Transformer	$0,1410 \pm 0,0254$	$0,0903 \pm 0,0252$
030	Вероятностная	$0,0676 \pm 0,0032$	$0,0106 \pm 0,0041$
030	Transformer	$0,2690 \pm 0,0169$	$0,2185 \pm 0,0162$
085	Вероятностная	$0,0372 \pm 0,0016$	$0,0028 \pm 0,0015$
085	Transformer	$0,1468 \pm 0,0051$	$0,1135 \pm 0,0051$

Transformer превосходит вероятностную модель по PR-AUC и recall для всех трех пользователей. Наилучший результат получен для пользователя 030: значение PR-AUC равно 0,2690, а recall при калиброванном пороге составляет 0,2185. Это означает, что модель не только лучше упорядочивает события по степени аномальности, но и обнаруживает большую долю внесенных отклонений после фиксации порога.

Для вероятностной модели значения PR-AUC близки к доле аномалий в тестовой выборке. Это показывает, что базовый способ частично отражает редкость отдельных событий, но слабо выделяет аномалии среди большого числа нормальных наблюдений. Особенно заметно это для пользователя 085: PR-AUC составляет 0,0372, а recall равен только 0,0028, то есть почти все внесенные отклонения остаются ниже порога обнаружения.

Средние значения по всем 30 сочетаниям пользователя и варианта формирования контрольной выборки приведены в таблице 4.10.

Таблица 4.10: Средние значения PR-AUC и recall по всем пользователям и вариантам контрольной выборки

Модель	PR-AUC	Recall
Вероятностная	$0,0563 \pm 0,0146$	$0,0096 \pm 0,0075$
Transformer	$0,1856 \pm 0,0617$	$0,1408 \pm 0,0584$

В среднем переход от вероятностной модели к Transformer увеличил PR-AUC на 0,1293, а recall - на 0,1312. Относительно базового способа PR-AUC вырос примерно в 3,30 раза, а recall - в 14,67 раза. Следовательно, преимущество Transformer проявляется не только в ранжировании событий, но и в фактическом обнаружении аномалий при пороге, выбранном без использования тестовой разметки.

4.2.7 Результаты для отдельных типов аномалий

Для более детального анализа результаты были сгруппированы по типам внесенных отклонений. Значения PR-AUC и recall усреднены по трем пользователям и десяти вариантам контрольной выборки и приведены в таблице 4.11.

Таблица 4.11: PR-AUC и recall для различных типов аномалий

Тип аномалии	PR-AUC		Recall	
	Вероятностная	Transformer	Вероятностная	Transformer
Нетипичная зона	$0,0199 \pm 0,0083$	$0,0454 \pm 0,0370$	$0,0079 \pm 0,0135$	$0,0693 \pm 0,0680$
Нетипичное время	$0,0368 \pm 0,0333$	$0,0582 \pm 0,0443$	$0,0247 \pm 0,0328$	$0,0935 \pm 0,0834$
Редкий переход	$0,0180 \pm 0,0063$	$0,0476 \pm 0,0367$	$0,0056 \pm 0,0099$	$0,0683 \pm 0,0660$
Контекстное нарушение	$0,0104 \pm 0,0031$	$0,2447 \pm 0,1079$	$0,0000 \pm 0,0000$	$0,3319 \pm 0,1256$

Transformer получил более высокие значения PR-AUC и recall для всех четырех типов аномалий. Наиболее выраженное различие наблюдается для контекстных нарушений. Вероятностная модель не обнаружила ни одного события этого типа во всех 30 вариантах эксперимента: средний recall равен нулю. У Transformer для контекстных нарушений значение PR-AUC составило 0,2447, а recall - 0,3319.

Такое различие объясняется способом учета контекста. Вероятностная модель при отсутствии точного перехода переходит к более общему уровню оценки. Поскольку измененное событие известно по обучающей истории и встречалось в том же временном интервале, после backoff оно

может получить достаточно высокую вероятность и не превысить порог. Transformer использует до 96 предыдущих токенов и оценивает событие не только по непосредственному предшественнику, но и по более широкой дневной последовательности. Поэтому он лучше выявляет ситуации, в которых отдельные компоненты события нормальны, но их положение в истории нетипично.

Для нетипичного времени Transformer также превосходит вероятностную модель по обоим метрикам. Для пространственных отклонений преимущество менее выражено, поскольку такие аномалии частично обнаруживаются по редкости зоны или перехода. Однако даже в этих случаях recall вероятностной модели остается низким, что показывает ограниченность базового способа при фиксированном пороге.

4.2.8 Влияние выбора порога

Дополнительный анализ показал, что результаты вероятностной модели существенно зависят от дискретности ее оценок. Вероятности в этой модели вычисляются по счетчикам событий и переходов, поэтому множество возможных значений оценок аномальности ограничено. В результате квантильный порог может совпасть с одним из часто встречающихся значений.

Для пользователя 002 в исходной тестовой последовательности было получено 132 различных значения вероятностной оценки. Порог

$$\theta_{prob} = 8,6913$$

совпал с максимальным значением оценки; 56 исходных событий получили оценку, точно равную этому порогу. Для пользователя 085 порог

$$\theta_{prob} = 9,2165$$

также совпал с максимальным тестовым значением, а число событий с такой оценкой составило 890.

Поскольку в вероятностной модели решение принимается при условии $A(e) > \theta$, события с оценкой, равной порогу, не признаются аномальными. Это объясняет малое число срабатываний и низкие значения recall.

У Transformer распределение значений оценок более непрерывно. В

исходных тестовых последовательностях было получено 1919, 7635 и 2971 различных значений оценки для пользователей 002, 030 и 085 соответственно. Поэтому квантильный порог точнее отделяет верхнюю часть распределения, а модель формирует больше осмысленных срабатываний.

Важно, что одинаковый принцип калибровки применялся к обеим моделям и не использовал тестовые метки. Следовательно, полученные результаты отражают не подбор порога под конкретные аномалии, а различие в форме распределений аномальных оценок, создаваемых частотной и нейросетевой моделями.

4.2.9 Ограничения эксперимента

Проведенное исследование имеет несколько ограничений, которые необходимо учитывать при интерпретации результатов.

Во-первых, исходные последовательности построены по реальным GPS-наблюдениям, но аномалии внесены искусственно. Поэтому количественные значения метрик характеризуют обнаружение четырех заданных типов изменений и не охватывают все возможные формы реального аномального поведения.

Во-вторых, события исходной тестовой части рассматриваются как нормальные. В реальной истории пользователя могли присутствовать естественные отклонения, не имеющие разметки. Такие события попадали в отрицательный класс и могли снижать рассчитанные значения метрик.

В-третьих, контрольные аномалии изменяют отдельное событие. Эксперимент не проверяет длительные аномальные периоды, состоящие из серии взаимосвязанных перемещений, например многодневное изменение привычного маршрута.

В-четвертых, исследование выполнено для трех пользователей. Эти пользователи различаются по объему истории, числу зон и регулярности поведения, однако они не покрывают все возможные сценарии мобильности.

Наконец, порог фиксировался как 0,99-квантиль калибровочных оценок и не оптимизировался по тестовой разметке. Это соответствует исходной постановке без размеченных аномалий, но означает, что полученные значения `recall` зависят от выбранного правила калибровки порога.

4.2.10 Выводы по результатам эксперимента

Проведенный эксперимент показал, что Transformer-модель более эффективно выявляет аномальные события в GPS-последовательностях, чем вероятностная модель с backoff, использованная как базовый способ сравнения. По всем 30 сочетаниям пользователя и варианта формирования контрольной выборки Transformer получил более высокие значения PR-AUC и recall.

Средний PR-AUC увеличился с 0,0563 до 0,1856, а средний recall - с 0,0096 до 0,1408. Наиболее существенное преимущество получено для контекстных нарушений: вероятностная модель не обнаружила ни одного события этого типа при калиброванном пороге, тогда как Transformer достиг среднего значения

$$Recall = 0,3319.$$

Результаты показывают, что частотная модель полезна как простой и интерпретируемый базовый способ. Она может ранжировать отдельные пространственные отклонения, связанные с редкостью зоны или перехода. Однако ее возможности ограничены коротким контекстом и дискретным распределением оценок, что приводит к малому числу срабатываний при квантильной калибровке порога.

Transformer учитывает более длинную предысторию событий и поэтому лучше обнаруживает отклонения, которые не сводятся к появлению новой зоны или редкого перехода. Это подтверждает целесообразность использования последовательной нейросетевой модели для построения профиля пользователя и последующего выявления аномального поведения на основе GPS-траекторий.

4.3 Выводы по главе

В экспериментальной главе были проверены два этапа построения профиля пользователя по GPS-траекториям.

В первой части исследовалось качество представлений траекторий для последующей группировки пользователей. При строгом разбиении по пользователям Transformer-представления показали более высокое качество кластеризации по сравнению с агрегированными признаками: значение ARI увеличилось с 0,0300 до 0,2648, а NMI - с 0,1280 до 0,2077. Это

означает, что модель способна извлекать из последовательности перемещений признаки, частично переносимые на пользователей, отсутствовавших при обучении.

Во второй части оценивалось выявление аномального поведения. Модели обучались только на нормальной истории пользователя, пороги выбирались по калибровочной части, а тестовая разметка использовалась исключительно для итоговой оценки. Transformer превзошел вероятностную модель по средним значениям PR-AUC и recall. Особенно заметное преимущество было получено для контекстных нарушений, где важна не только редкость отдельного события, но и его положение в последовательности.

Полученные результаты подтверждают, что последовательные модели на основе Transformer подходят для обеих рассматриваемых задач: формирования представлений GPS-траекторий и выявления отклонений от индивидуального профиля мобильности. При этом значения метрик показывают, что задача остается сложной: для новых пользователей качество группировки неполное, а обнаружение аномалий зависит от выбранного порога и характера отклонений.

Заключение

В ходе выполнения дипломной работы были исследованы методы машинного обучения для построения профиля пользователя по данным о его местоположении.

Были рассмотрены особенности GPS-траекторий как источника информации о поведении пользователей, проанализированы существующие подходы к их обработке и исследованы методы построения пользовательских профилей на основе данных о перемещениях.

В рамках работы разработано программное средство для анализа GPS-траекторий пользователей. Проведённые экспериментальные исследования на реальных данных подтвердили возможность построения профиля пользователя на основе информации о его местоположении и продемонстрировали эффективность предложенного подхода.

Полученные результаты могут быть использованы при создании систем анализа мобильности пользователей, сервисов персонализации и интеллектуальных геоинформационных систем.

Таким образом, цель работы достигнута, а поставленные задачи решены.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Zheng Y., Xie X., Ma W.-Y. GeoLife: A Collaborative Social Networking Service among User, Location and Trajectory // IEEE Data Engineering Bulletin. 2010. Vol. 33, no. 2. P. 32–39.
- [2] Vaswani A., Shazeer N., Parmar N., et al. Attention Is All You Need // Advances in Neural Information Processing Systems. 2017. Vol. 30.
- [3] Khosla P., Teterwak P., Wang C., et al. Supervised Contrastive Learning // Advances in Neural Information Processing Systems. 2020. Vol. 33. P. 18661–18673.
- [4] Murtagh F., Contreras P. Algorithms for Hierarchical Clustering: An Overview // WIREs Data Mining and Knowledge Discovery. 2012. Vol. 2, no. 1. P. 86–97. DOI: 10.1002/widm.53.
- [5] Salton G., Buckley C. Term-Weighting Approaches in Automatic Text Retrieval // Information Processing & Management. 1988. Vol. 24, no. 5. P. 513–523. DOI: 10.1016/0306-4573(88)90021-0.
- [6] Hubert L., Arabie P. Comparing Partitions // Journal of Classification. 1985. Vol. 2, no. 1. P. 193–218. DOI: 10.1007/BF01908075.
- [7] Vinh N. X., Epps J., Bailey J. Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance // Journal of Machine Learning Research. 2010. Vol. 11. P. 2837–2854.
- [8] McInnes L., Healy J., Melville J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction // arXiv preprint arXiv:1802.03426. 2018.
- [9] Chen S. F., Goodman J. An Empirical Study of Smoothing Techniques for Language Modeling // Computer Speech & Language. 1999. Vol. 13, no. 4. P. 359–394. DOI: 10.1006/csla.1999.0128.

- [10] Bengio Y., Ducharme R., Vincent P., Jauvin C. A Neural Probabilistic Language Model // Journal of Machine Learning Research. 2003. Vol. 3. P. 1137–1155.
- [11] Chandola V., Banerjee A., Kumar V. Anomaly Detection: A Survey // ACM Computing Surveys. 2009. Vol. 41, no. 3. Article 15. DOI: 10.1145/1541880.1541882.
- [12] Davis J., Goadrich M. The Relationship Between Precision-Recall and ROC Curves // Proceedings of the 23rd International Conference on Machine Learning. 2006. P. 233–240. DOI: 10.1145/1143844.1143874.
- [13] Powers D. M. W. Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation // Journal of Machine Learning Technologies. 2011. Vol. 2, no. 1. P. 37–63.
- [14] Fawcett T. An Introduction to ROC Analysis // Pattern Recognition Letters. 2006. Vol. 27, no. 8. P. 861–874. DOI: 10.1016/j.patrec.2005.10.010.
- [15] Sinnott R. W. Virtues of the Haversine // Sky and Telescope. 1984. Vol. 68, no. 2. P. 159.
- [16] Ester M., Kriegel H.-P., Sander J., Xu X. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise // Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. 1996. P. 226–231.
- [17] Campello R. J. G. B., Moulavi D., Sander J. Density-Based Clustering Based on Hierarchical Density Estimates // Advances in Knowledge Discovery and Data Mining. Berlin: Springer, 2013. P. 160–172. DOI: 10.1007/978-3-642-37456-2_14.
- [18] Li X., Zhao K., Cong G., Jensen C. S., Wei W. Deep Representation Learning for Trajectory Similarity Computation // 2018 IEEE 34th International Conference on Data Engineering. 2018. P. 617–628. DOI: 10.1109/ICDE.2018.00062.

- [19] MacQueen J. Some Methods for Classification and Analysis of Multivariate Observations // Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. 1967. Vol. 1. P. 281–297.
- [20] Zhou F., Gao Q., Trajcevski G., Zhang K., Zhong T., Zhang F. Trajectory-User Linking via Variational AutoEncoder // Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence. 2018. P. 3212–3218.
- [21] Miao C., Wang J., Yu H., Zhang W., Qi Y. Trajectory-User Linking with Attentive Recurrent Network // Proceedings of the 19th International Conference on Autonomous Agents and MultiAgent Systems. 2020. P. 878–886.
- [22] Chen W., Huang C., Yu Y., Jiang Y., Dong J. Trajectory-User Linking via Hierarchical Spatio-Temporal Attention Networks // ACM Transactions on Knowledge Discovery from Data. 2024. Vol. 18, no. 4. Article 83.
- [23] Rumelhart D. E., Hinton G. E., Williams R. J. Learning Representations by Back-Propagating Errors // Nature. 1986. Vol. 323. P. 533–536. DOI: 10.1038/323533a0.
- [24] Hochreiter S., Schmidhuber J. Long Short-Term Memory // Neural Computation. 1997. Vol. 9, no. 8. P. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
- [25] Cho K., van Merriënboer B., Gulcehre C., et al. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation // Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. 2014. P. 1724–1734. DOI: 10.3115/v1/D14-1179.
- [26] Press O., Wolf L. Using the Output Embedding to Improve Language Models // Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. 2017. Vol. 2. P. 157–163.
- [27] Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proceedings of the 2019 Conference of the North American Chapter of the Association for

Computational Linguistics. 2019. P. 4171–4186. DOI: 10.18653/v1/N19-1423.

- [28] Ba J. L., Kiros J. R., Hinton G. E. Layer Normalization // arXiv preprint arXiv:1607.06450. 2016.
- [29] Cover T., Hart P. Nearest Neighbor Pattern Classification // IEEE Transactions on Information Theory. 1967. Vol. 13, no. 1. P. 21–27. DOI: 10.1109/TIT.1967.1053964.
- [30] Breunig M. M., Kriegel H.-P., Ng R. T., Sander J. LOF: Identifying Density-Based Local Outliers // Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data. 2000. P. 93–104. DOI: 10.1145/335191.335388.
- [31] Liu F. T., Ting K. M., Zhou Z.-H. Isolation Forest // Proceedings of the 8th IEEE International Conference on Data Mining. 2008. P. 413–422.
- [32] Rabiner L. R. A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition // Proceedings of the IEEE. 1989. Vol. 77, no. 2. P. 257–286.